

MF矩阵分解 -- SVD、LFM、RSVD、SVD++ (Matrix Factorization)

- 针对问题:

协同过滤处理稀疏矩阵的能力较弱

协同过滤中, 相似度矩阵维护难度大

- 解决思路:

	音乐A	音乐B	音乐C
张三	0.68	1.58	0.28
李四	0.31	0.43	0.47
王五	1.06	1.57	0.73

3x3

=

	小清新	重口味	优雅	伤感	五月天
张三	0.6	0.8	0.1	0.1	0.7
李四	0.1	0	0.9	0.1	0.2
王五	0.5	0.7	0.9	0.9	0

3x4

×

	音乐A	音乐B	音乐C
小清新	0.9	0.5	0
重口味	0.1	0.6	0.6
优雅	0.2	0.1	0.1
伤感	0.4	0.9	0.2
五月天	0	1	0

4x3

		物品			
		W	X	Y	Z
用户	A		4.5	2.0	
	B	4.0		3.5	
	C		5.0		2.0
	D		3.5	4.0	1.0

共现矩阵 $R: m \times n$

=

		k1	k2
用户矩阵 U	A	1.2	0.8
	B	1.4	0.9
	C	1.5	1.0
	D	1.2	0.8

$m \times k$

×

		W	X	Y	Z
物品矩阵 V	k1	1.5	1.2	1.0	0.8
	k2	1.7	0.6	1.1	0.4

$k \times n$

-

- 隐含特征是不可解释的, 需要模型自己学习
- k的大小决定隐向量表达能力强弱, k越大表达能力越强, 用户兴趣和物品分类具体
- 通过用户矩阵和物品矩阵预测评分计算公式:

$$Preference(n, i) = r_{ui} = \sum_{f=1}^F p_{u,k} q_{k,i} \quad (\text{对应向量内积})$$

- MF方式

- 特征值分解

- 特征值, 特征向量: $Av = \lambda v$

v 是特征向量, λ 是特征值

- 特征值分解: $A = Q \Sigma Q^{-1}$

Q 代表矩阵A的特征向量构成的矩阵

Σ 是对角阵, 对角线的元素是特征值

- 奇异值分解 (SVD) :

- 定义: $A = U \Sigma V^T$

其中 A 是实矩阵, $UU^T = I, VV^T = I$

Σ 是对角矩阵, 对角线元素非负且降序排列

$$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 4 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 2 & 0 & 0 & 0 \end{bmatrix}_{5 \times 4} = \begin{bmatrix} 0 & 0 & \sqrt{0.2} & 0 & \sqrt{0.8} \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & \sqrt{0.8} & 0 & -\sqrt{0.2} \end{bmatrix}_{5 \times 5} \times \begin{bmatrix} 4 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & \sqrt{5} & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}_{5 \times 4} \times \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}_{4 \times 4}$$

A
 U
 Σ
 V^T

$UU^T = I_5$,
 对角线外的元素都是 0,
 对角线上的元素非负,
 按降序排列。
 $VV^T = I_4$

■ 计算步骤

A是一个m*n的实矩阵

1. 构造n阶实对称矩阵 $W = A^T A$
2. 计算W的特征值与特征向量

求解特征方程

$$(W - \lambda I)x = 0$$

得到特征值 λ_i , 并将特征值由大到小排列

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$

将特征值 $\lambda_i (i = 1, 2, \dots, n)$ 代入特征方程求得对应的特征向量。

3. 求得n阶正交矩阵V

将特征向量单位化, 得到单位特征向量 v_1, v_2, \dots, v_n , 构成n阶正交矩阵V:

$$V = [v_1 \ v_2 \ \dots \ v_n]$$

4. 求得m*n对角矩阵

计算A的奇异值

$$\sigma_i = \sqrt{\lambda_i}, \quad i = 1, 2, \dots, n$$

构造 $m \times n$ 矩形对角矩阵 Σ , 主对角线元素是奇异值, 其余元素是零,

$$\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_n)$$

5. 求得m阶正交矩阵U (求得上述)

■ 求U1

对A的前r个正奇异值, 令

$$u_j = \frac{1}{\sigma_j} A v_j, \quad j = 1, 2, \dots, r$$

得到

$$U_1 = [u_1 \ u_2 \ \dots \ u_r]$$

■ 求U2

求 A^T 的零空间的一组标准正交基 $\{u_{r+1}, u_{r+2}, \dots, u_m\}$, 令

$$U_2 = [u_{r+1} \ u_{r+2} \ \dots \ u_m]$$

- 得到 $U=[U1, U2]$

- 缺点:

传统SVD分解会要求原始矩阵是稠密的，所以我们需要对缺失进行填补，空间复杂度非常高，基本无法解决大规模稀疏矩阵的矩阵分解问题

○ Basic SVD (LFM, Funk SVD)

- 将矩阵分解问题转化为**最优化问题**，通过梯度下降进行优化
- 预测函数:

$$\text{Preference}(u, i) = r_{ui} = p_u^T q_i = \sum_{f=1}^F p_{u,k} q_{k,i}$$

- 损失函数（误差平方和）:

式子2便于优化

$$\text{SSE} = \sum_{u,i} e_{ui}^2 = \sum_{u,i} \left(r_{ui} - \sum_{k=1}^K p_{u,k} q_{k,i} \right)^2$$

$$\text{SSE} = \frac{1}{2} \sum_{u,i} e_{ui}^2 = \frac{1}{2} \sum_{u,i} \left(r_{ui} - \sum_{k=1}^K p_{uk} q_{ki} \right)^2$$

- 步骤:
 1. 首先初始化这两个矩阵
 2. 把用户评分矩阵里面已经评过的那些样本当做训练集的label，把对应的用户和物品的隐向量当做features，这样就会得到(features, label)相当于训练集
 3. 通过两个隐向量乘积得到预测值pred
 4. 根据label和pred计算损失
 5. 然后反向传播，通过梯度下降的方式，更新两个隐向量的值
 6. 未评过的那些样本当做测试集，通过两个隐向量就可以得到测试集的label值
 7. 这样就填充完了矩阵，下一步就可以进行推荐了

○ RSVD

在Basic SVD基础上，加入正则化参数（惩罚项）

预测函数:

$$\text{Preference}(u, i) = r_{ui} = p_u^T q_i = \sum_{f=1}^F p_{u,k} q_{k,i}$$

目标函数:

$$\begin{aligned}
 SSE &= \frac{1}{2} \sum_{u,i} e_{ui}^2 + \frac{1}{2} \lambda \sum_u |p_u|^2 + \frac{1}{2} \lambda \sum_i |q_i|^2 \\
 &= \frac{1}{2} \sum_{u,i} e_{ui}^2 + \frac{1}{2} \lambda \sum_u \sum_{k=0}^K p_{u,k}^2 + \frac{1}{2} \lambda \sum_i \sum_{k=0}^K q_{k,i}^2
 \end{aligned}$$

改进 (LFM) :

Netflix提出另外一种LFM，在原有基础上加偏置项，消除用户和物品打分的偏差

原因：不同用户打分体系不同，不同物品衡量标准有区别，导致评分偏差

$$\hat{r}_{ui} = \mu + b_u + b_i + p_u^T \cdot q_i$$

评分的全局平均数 用户评分偏差 物品得分偏差

目标函数：

$$\begin{aligned}
 SSE &= \frac{1}{2} \sum_{u,i} e_{ui}^2 + \frac{1}{2} \lambda \sum_u |p_u|^2 + \frac{1}{2} \lambda \sum_i |q_i|^2 + \frac{1}{2} \lambda \sum_u b_u^2 + \frac{1}{2} \lambda \sum_i b_i^2 \\
 &= \frac{1}{2} \sum_{u,i} \left(r_{ui} - \mu - b_u - b_i - \sum_{k=1}^K p_{uk} q_{ki} \right)^2 + \frac{1}{2} \lambda \sum_u |p_u|^2 + \frac{1}{2} \lambda \sum_i |q_i|^2 + \frac{1}{2} \lambda \sum_u b_u^2 + \frac{1}{2} \lambda \sum_i b_i^2
 \end{aligned}$$

o SVD++

改进方向：用户历史记录会对新评分产生影响（即物品间存在某些联系），交给模型学习

首先把ItemCF的预测算法改成一个可以学习的模型，就行LFM那样，怎么改？ItemCF的预测算法公式如下：

$$\hat{r}_{ui} = \frac{1}{\sqrt{|N(u)|}} \sum_{j \in N(u)} w_{ij}$$

还记得ItemCF吗？这个式子是预测用户 u 对于物品 i 的打分， $N(u)$ 表示用户 u 打过分的历史物品， w_{ij} 表示物品 i,j 的相似度，当然这里的这个相似度不再是ItemCF那样，通过向量计算的，而是想向LFM那样，让模型自己学出这个参数来，那么相应的就可以通过优化的思想嘛：

$$SSE = \sum_{(u,i) \in \text{Train}} \left(r_{ui} - \sum_{j \in N(u)} w_{ij} r_{uj} \right)^2 + \lambda w_{ij}^2$$

但是呢，这么模型有个问题，就是 w 比较稠密，存储需要很大的空间，因为如果有 n 个物品，那么模型的参数就是 n^2 ，参数一多，就容易造成过拟合。所以Koren提出应该对 w 矩阵进行分解，将参数降到了 $2 * n * F$ ：

$$\hat{r}_{ui} = \frac{1}{\sqrt{|N(u)|}} \sum_{j \in N(u)} x_i^T y_j = \frac{1}{\sqrt{|N(u)|}} x_i^T \sum_{j \in N(u)} y_j$$

相当于用 $x_i^T y_j$ 代替了 w_{ij} ，这里的 x_i, y_j 是两个 F 维的向量。**有没有发现在这里，就出现了点FM的改进身影了。**这里其实就是又对物品 i 和某个用户 u 买过的历史物品又学习一波隐向量，这次是 F 维，为了衡量出物品 i 和历史物品 j 之间的相似性来。这时候，参数的数量降了下来，并同时考虑进来了用户的历史物品记录。所以这个和之前的LFM相加就得到了：

$$\hat{r}_{ui} = \mu + b_u + b_i + p_u^T \cdot q_i + \frac{1}{\sqrt{|N(u)|}} x_i^T \sum_{j \in N(u)} y_j$$

前面的是我们之前分析的LFM模型，而后面的这个是考虑进了用户购买的历史物品。但是这样感觉参数太多了，所以Koren提出令 $x = q$ ，因为既然同是商品 i ，就没有必要学习两个隐向量了嘛，所以得到了该模型的最终预测方式：

$$\hat{r}_{ui} = \mu + b_u + b_i + q_i^T \left(p_u + \frac{1}{\sqrt{|N(u)|}} \sum_{j \in N(u)} y_j \right)$$

这一个就是SVD++模型了。有了预测函数，然后也知道真实值，就可以由损失函数对各个参数求偏导，和上面的一样了，这里直接给出导数了，不推了：

$$e_{ui} = r_{ui} - \hat{r}_{ui}$$

$$b_u \leftarrow b_u + \gamma \cdot (e_{ui} - \lambda \cdot b_u)$$

$$b_i \leftarrow b_i + \gamma \cdot (e_{ui} - \lambda \cdot b_i)$$

$$p_u \leftarrow p_u + \gamma \cdot (e_{ui} \cdot q_i - \lambda \cdot p_u)$$

$$q_i \leftarrow q_i + \gamma \cdot (e_{ui} \cdot (p_u + \frac{1}{\sqrt{\|R_u\|}} \sum_{j \in R_u} y_j) - \lambda \cdot q_i)$$

$$y_j \leftarrow y_j + \gamma (e_{ui} \cdot \frac{1}{\sqrt{\|R_u\|}} \cdot q_i - \lambda \cdot q_i)$$
